Sistemas Inteligentes - Segunda Parte Trabajo Integrador

EL ROL DE LA INTELIGENCIA ARTIFICIAL EN EL DIAGNÓSTICO MÉDICO ASISTIDO

Abatedaga Brenda, Colavita Melisa y Wampl Emiliano

Dr. Miguel Méndez Garabetti, Ing. Eduardo Piray
Universidad CAECE SEDE MAR DEL PLATA

Índice

Resumen **3**
Introducción **3**
Relación con la Asignatura: Sistemas Inteligentes **4**
Estudio de Caso: IA vs. Radiólogo en Diagnóstico Mamográfico **6**
Qué miden sensibilidad, especificidad y AUC-ROC 6
Estudio A: Google Health en Nature (2020) **7**
Resultados 7
Limitaciones 7
Estudio B: Ensayo MASAI, Suecia (2021–2026) **7**
Diseño 8
Resultados intermedios (Lancet Oncology, 2023) 8
Resultados finales (The Lancet, enero 2026) 8
Desarrollo del trabajo **10**
Conjunto de datos y fusión de fuentes 10
Preprocesamiento 10
Arquitectura de la red 11
Entrenamiento 11
Resultados obtenidos 12
Interpretación de resultados 12
Reflexión crítica sobre la implementación de la IA en el sistema de salud **15**
Aspectos éticos 15
Aspectos regulatorios 16
Aspectos de adopción en el sistema de salud 17
Conclusión **18**
Bibliografía **19**

Resumen

El presente trabajo aborda el rol de la inteligencia artificial en el diagnóstico médico asistido, tomando como caso de estudio el sistema de Google Health publicado en Nature en 2020, para la detección de cáncer de mama en mamografías.

El objetivo general fue evaluar el nivel de confianza que puede depositarse en estos sistemas, analizando su desempeño en términos de sensibilidad, especificidad y comparación con el diagnóstico humano. Como componente práctico, se implementó desde cero una red neuronal convolucional CNN para clasificar mamografías entre casos benignos y malignos, analizando su comportamiento frente al aumento de la cantidad de épocas de entrenamiento. Los resultados confirmaron que una CNN es capaz de aprender distintos patrones en mamografías, aunque también se evidenció una considerable brecha que existe entre dicha implementación y un sistema de nivel clínica, una brecha que no es fundamentalmente algorítmica sino de datos, recursos y validación.

Introducción

La aplicación de inteligencia artificial al diagnóstico médico por imágenes es uno de los avances más comentados en los últimos años, y también uno de los más delicados: se trata de incorporar sistemas automatizados a decisiones de las que depende la salud, e incluso la vida, de las personas. El presente trabajo aborda ese papel de la IA en el diagnóstico médico asistido, tomando como referencia su aplicación a la detección de cáncer de mama en mamografías.

Lo que despertó el interés al grupo fue, precisamente, la seguridad con la que se propone aplicar inteligencia artificial a un terreno tan sensible como la salud. Que un sistema automatizado intervenga en este tipo de decisiones plantea preguntas de fondo: ¿ Con qué grado de confianza puede delegar esa tarea en una IA? ¿Bajo qué condiciones su uso resulta correcto y sobre todo, confiable? Estos interrogantes motivaron la elección del tema y orientaron el trabajo.

Por eso, se eligió como caso de estudio el sistema desarrollado por Google Health y publicado en Nature en 2020, siendo uno de los primeros trabajos a gran escala en evaluar si un sistema de IA puede igualar, o incluso superar, el desempeño de radiólogos expertos. El interés por este caso no radicó únicamente en los resultados, sino en la oportunidad de comprender el funcionamiento de un clasificador de imágenes médicas: las decisiones de diseño que involucra, las dificultades prácticas de su implementación y la distancia real entre los resultados publicados y los alcanzables en un entorno académico. Con ese fin, además de analizar el estudio de caso, se desarrolló una implementación propia de la red neuronal convolucional.

Relación con la Asignatura: Sistemas Inteligentes

El presente trabajo se articula de manera directa con los contenidos centrales de la asignatura. El caso analizado, la evaluación de IA en diagnóstico mamográfico, es una aplicación real y de alto impacto que permite recorrer los temas del programa a través de un problema concreto con consecuencias clínicas demostrables.

La asignatura introduce los sistemas inteligentes a partir del reconocimiento de patrones y los modelos de clasificación y predicción. El diagnóstico mamográfico asistido por IA es exactamente ese problema: el sistema recibe una imagen, extrae patrones visuales como bordes, densidades, texturas y microcalcificaciones, y los clasifica en dos categorías, maligno o benigno. Las métricas centrales del trabajo, sensibilidad, especificidad y AUC-ROC, son las herramientas estándar para evaluar cualquier clasificador, y aquí adquieren una dimensión concreta: un error de clasificación no es solo un dato estadístico, es un cáncer no detectado o una biopsia innecesaria.

La conexión más directa con la asignatura es a través de las redes neuronales artificiales. Los sistemas evaluados en Google Health y el ensayo MASAI están construidos sobre redes neuronales convolucionales profundas (CNN), que son una extensión especializada del perceptrón multicapa. La arquitectura sigue exactamente el esquema trabajado en clase: capas de entrada que reciben los píxeles de la imagen, capas ocultas que aprenden representaciones jerárquicas de características visuales, y una capa de salida que emite la probabilidad de malignidad. El entrenamiento utiliza retropropagación del error para ajustar los pesos minimizando la diferencia entre el diagnóstico del modelo y el diagnóstico confirmado por biopsia. Los métodos para reducir el error como la regularización, el dropout, el ajuste de la tasa de aprendizaje y los pesos de clase para datasets desbalanceados son críticos en este contexto y constituyen decisiones de diseño que la asignatura trabaja de forma aplicada.

Para la implementación desarrollada en el trabajo, se construyó una CNN desde cero con capas Conv2D y MaxPooling, herramientas que la asignatura propone para diseñar redes neuronales orientadas a clasificación y visión artificial. Este proceso permitió atravesar de forma práctica cada etapa del diseño de una red neuronal: definición de la arquitectura, preprocesamiento de datos, entrenamiento y evaluación de métricas, siguiendo el enfoque que propone la materia.

La asignatura destaca la visión artificial como uno de los campos de aplicación de las redes neuronales, y el análisis de mamografías es un caso paradigmático de esa área. El sistema aprende a detectar patrones visuales en imágenes médicas de alta resolución, aplicando las mismas operaciones de convolución que permiten a cualquier sistema de visión por computadora reconocer estructuras en una imagen. La diferencia es que aquí esos patrones

son microcalcificaciones, masas y asimetrías con consecuencias diagnósticas directas para la paciente.

Asimismo la asignatura plantea explícitamente un enfoque práctico orientado a inteligencia artificial, con Python como lenguaje principal y Google Colab como entorno de ejecución en la nube. El trabajo se desarrolló íntegramente en ese entorno: la CNN fue implementada en Python, entrenada en Google Colab con acceso a GPU y evaluada con métricas estándar de clasificación. De esta forma, se aplicó directamente el enfoque que propone la materia: diseñar la red, definir sus capas, entrenarla y analizar sus resultados en un entorno accesible y reproducible.

Finalmente, el modelo de integración clínica validado por el ensayo MASAI representa un sistema híbrido en el sentido preciso que trabaja la asignatura: combina una CNN profunda para el análisis de imagen, un módulo de scoring continuo para la asignación de riesgo, y la supervisión de un radiólogo humano como agente decisor final. Ninguno de esos tres componentes produce por sí solo el resultado óptimo; es su combinación estructurada la que logra los mejores resultados tanto en detección como en eficiencia operativa. El uso de transfer learning sobre redes preentrenadas como ResNet o EfficientNet también responde a este principio: combinar el conocimiento aprendido en grandes datasets generales con el ajuste fino sobre datos médicos específicos para obtener un sistema más robusto que cualquiera de sus partes por separado.

En síntesis, el trabajo usa el caso de la IA en mamografía como hilo conductor que integra reconocimiento de patrones, arquitecturas neuronales, entrenamiento y reducción del error, visión artificial, implementación en Python y Colab, y sistemas híbridos, todo en un único problema real con datos publicados, métricas verificables e impacto clínico demostrado en más de 100.000 pacientes.

Estudio de Caso: IA vs. Radiólogo en Diagnóstico Mamográfico

El cáncer de mama es el tumor maligno más frecuente en mujeres a nivel mundial. La mamografía de cribado, es decir, el estudio de imágenes que se hace de forma preventiva antes de que aparezcan síntomas, es el método estándar de detección precoz. Sin embargo, enfrenta dos problemas persistentes: una tasa de errores de detección de entre el 10% y el 30%, y una marcada variabilidad entre radiólogos que puede alcanzar el 30% incluso en centros especializados. A esto se suma una escasez crónica de especialistas.

En este contexto, los sistemas de inteligencia artificial basados en aprendizaje profundo emergieron como una alternativa prometedora. La pregunta central no era si la IA podía procesar imágenes médicas, eso ya estaba claro, sino si podía hacerlo con suficiente precisión para ser confiable en la práctica clínica real.

Los dos estudios que mejor responden a esa pregunta son el trabajo de Google Health publicado en *Nature* en 2020 y el ensayo aleatorizado MASAI conducido en Suecia entre 2021 y 2026.

Qué miden sensibilidad, especificidad y AUC-ROC

Antes de analizar los resultados es necesario entender estas métricas, porque en diagnóstico oncológico cada tipo de error tiene consecuencias distintas.

La sensibilidad mide cuántos cánceres reales detecta el sistema. Una sensibilidad alta significa que el modelo no "deja pasar" casos enfermos. El error contrario, clasificar como sana a una mujer con cáncer, se llama falso negativo y es el más grave clínicamente, porque la enfermedad avanza sin tratamiento.

La especificidad mide cuántos casos sanos el sistema identifica correctamente como tales. Una especificidad baja genera falsos positivos: pacientes sin cáncer que son derivadas a biopsia de forma innecesaria, con el consiguiente costo emocional, físico y económico.

La curva ROC (*Receiver Operating Characteristic*) es un gráfico que muestra el equilibrio entre sensibilidad y especificidad a distintos umbrales de decisión. El AUC-ROC, el área bajo esa curva, resume el rendimiento global del modelo en un solo número: 1,0 es perfecto, 0,5 equivale a decidir al azar, y valores por encima de 0,85 se consideran clínicamente relevantes.

La tensión de fondo es que ningún umbral de decisión maximiza ambas métricas a la vez: subir la sensibilidad implica más falsos positivos; bajar los falsos positivos implica aceptar más cánceres no detectados. Resolver esa tensión es exactamente lo que los dos estudios analizados intentan lograr con apoyo de IA.

Estudio A: Google Health en *Nature* (2020)

En enero de 2020, McKinney y colaboradores publicaron en *Nature* el primer trabajo de gran escala que evaluó si un sistema de deep learning podía superar a radiólogos expertos en mamografía preventiva.

El estudio utilizó datos de dos países: 25.856 mamografías del Reino Unido con seguimiento de 39 meses para confirmar diagnósticos, y 3.097 estudios de EE.UU. con mayor proporción de casos positivos. El modelo era una red neuronal convolucional que procesaba las cuatro vistas estándar de una mamografía y producía una probabilidad de malignidad. Una limitación clave: los radiólogos leyeron los casos sin historial clínico de la paciente, condición que no representa la práctica real y que subestimó el rendimiento del especialista.

Resultados

El sistema alcanzó AUC de 0,966 en EE.UU. y 0,889 en Reino Unido, superando a los seis radiólogos del estudio por un margen de 11,5 puntos porcentuales. Clínicamente, redujo un 9,4% los falsos negativos en Reino Unido y un 5,7% los falsos positivos en EE.UU. En la simulación de doble lectura, la IA mantuvo rendimiento equivalente al estándar humano y redujo la carga del segundo lector en un 88%. Un análisis posterior sobre 115.973 mamografías del NHS confirmó estos hallazgos, con AUC de 0,978, sensibilidad de 0,913 y especificidad de 0,941.

Limitaciones

El diseño retrospectivo limita la validez de las conclusiones. No se publicaron resultados desagregados por etnia ni densidad mamaria, factor relevante porque los modelos CNN tienden a ser menos precisos en mamas densas, más frecuentes en mujeres jóvenes y ciertas poblaciones. Además, el estudio fue íntegramente financiado y ejecutado por Google Health sin revisión independiente, lo que la comunidad científica señaló como un conflicto de interés.

Estudio B: Ensayo MASAI, Suecia (2021–2026)

Google Health demostró capacidad técnica en condiciones controladas, pero la medicina basada en evidencia exige un paso más: un ensayo controlado aleatorizado (RCT), el diseño más riguroso para demostrar que una intervención funciona en la práctica real. Esa es la contribución del MASAI (*Mammography Screening with Artificial Intelligence*), el primer RCT que evaluó IA dentro de un programa nacional de cribado mamográfico.

Diseño

Más de 100.000 mujeres de entre 40 y 80 años fueron asignadas aleatoriamente a dos grupos. El grupo con IA (53.043 participantes) usó el sistema Transpara, que asignaba a cada mamografía un puntaje de riesgo del 1 al 10: los estudios de bajo riesgo iban a un único radiólogo y los de alto riesgo a doble lectura. El grupo control (≈47.000 participantes) recibió la doble lectura estándar sin IA. El indicador principal fue la tasa de cánceres de intervalo, tumores no detectados que aparecen entre dos rondas de cribado, los más agresivos y de peor pronóstico, y por eso el más importante para evaluar si el cribado realmente funciona.

Resultados intermedios (Lancet Oncology, 2023)

Al alcanzar los 80.000 casos, el grupo con IA detectó 244 cánceres (6,1 por 1.000) frente a 203 en el control (5,1 por 1.000), un aumento del 20% en detección. La carga de trabajo radiológica se redujo un 44,3% sin ningún aumento en falsos positivos.

Resultados finales (The Lancet, enero 2026)

El grupo con IA alcanzó sensibilidad del 80,5% frente al 73,8% del control, manteniendo la misma especificidad del 98,5%: con idéntica tasa de falsas alarmas, la IA detectó un 6,7% más de cánceres reales. La detección total aumentó un 29%, los cánceres de intervalo se redujeron un 12% y, entre los que igual ocurrieron, un 27% menos correspondió a subtipos agresivos.
Esto descarta el sobrediagnóstico: la IA adelantó tumores progresivos con impacto real, no detectó cánceres indolentes que no habrían avanzado.
La investigadora principal fue explícita: el estudio no avala reemplazar profesionales con IA. El cribado asistido sigue requiriendo al menos un radiólogo humano para la decisión final.

Comparación directa: IA vs. radiólogo

Google Health, en condición retrospectiva, superó a radiólogos individuales por 11,5 puntos de AUC y redujo falsos negativos un 9,4%, aunque los radiólogos operaban sin historial clínico, condición que favorece al modelo artificialmente.
El MASAI, en condición prospectiva y aleatoria, el estándar más exigente de evidencia, demostró que la IA asistida logra una sensibilidad 6,7 puntos superior a la doble lectura estándar a igual especificidad, reduce los cánceres de intervalo un 12% y la carga de trabajo un 44%, sin incrementar falsos positivos.
Los dos estudios llegaron al mismo punto: la IA detecta más cánceres reales (mayor sensibilidad) sin generar más falsas alarmas (sin perder especificidad). Eso es técnicamente

valioso. Pero el dato más importante no es solo que la IA funciona bien, sino cómo funciona mejor.

Cuando la IA opera sola, sin ningún radiólogo que revise su decisión, los riesgos son mayores: puede fallar de formas sistemáticas que nadie detecta a tiempo, y no hay nadie que incorpore el contexto clínico de la paciente , su historial, sus síntomas, sus antecedentes familiares, que la imagen sola no muestra.

En cambio, cuando la IA trabaja junto al radiólogo, señalando zonas sospechosas, priorizando los casos de mayor riesgo, los resultados mejoran para ambos: el radiólogo detecta más con menos esfuerzo, y la IA aporta consistencia donde el humano puede fatigarse o vacilar.

La IA sola es poderosa pero riesgosa; el radiólogo solo es experto pero limitado en volumen y consistencia. Juntos, cada uno compensa la debilidad del otro. Ese es el modelo colaborativo, y es el único que la evidencia actual respalda para uso clínico real.

Desarrollo del trabajo

El estudio de Google Health publicado en Nature presenta su metodología y sus resultados, pero no pone a disposición ni el código de implementación ni el modelo entrenado, debido a la confidencialidad de los datos clínicos utilizados y a la propiedad intelectual del sistema. Por este motivo, y con el objetivo de comprender de manera integral el funcionamiento de un clasificador de imágenes médicas, se decidió desarrollar una red neuronal convolucional (CNN) propia desde cero, empleando capas Conv2D y MaxPooling abordadas en la cursada. Esta decisión permitió no depender de modelos preentrenados y analizar de extremo a extremo cada etapa del proceso, desde la carga de los datos hasta la evaluación de resultados.

Conjunto de datos y fusión de fuentes

Dado que los datos originales empleados por Google Health no son de acceso público, se trabajó con el dataset VinDr-Mammo, un conjunto abierto de mamografías reales con sus respectivas anotaciones clínicas. Las imágenes y las anotaciones se obtuvieron de dos fuentes separadas en Kaggle: por un lado, las mamografías en formato PNG (convertidas desde el formato médico estándar DICOM), y por otro, un archivo CSV con las etiquetas. La integración de ambas fuentes requirió indexar cada imagen por su identificador único y cruzarla con su anotación correspondiente.

El etiquetado se basó en la clasificación BI-RADS, escala estándar utilizada por los radiólogos para categorizar el nivel de riesgo. Se transformó el problema en una clasificación binaria: las categorías BI-RADS 1 y 2 se consideraron benignas (etiqueta 0) y las categorías 4 y 5 malignas (etiqueta 1), descartando los casos intermedios para entrenar el modelo con ejemplos de clase definida. Debido al marcado desbalance del conjunto —con una proporción de casos benignos muy superior a la de malignos, tal como ocurre en la realidad clínica— se incluyeron todas las imágenes malignas disponibles y se completó con benignas hasta conformar un subconjunto de 10.000 imágenes. Adicionalmente, se aplicaron pesos de clase (*class weights*) durante el entrenamiento para penalizar con mayor intensidad los errores sobre la clase minoritaria.

Preprocesamiento

Cada mamografía presenta una amplia región de fondo negro alrededor del tejido. Por ello, antes del entrenamiento se aplicó un recorte automático de la región de interés (ROI), detectando el *bounding box* del tejido mamario y descartando el fondo. Posteriormente, las imágenes se redimensionaron a 1024×1024 píxeles y se normalizaron sus valores al rango [0,1]. Sobre el conjunto de entrenamiento se aplicó además *data augmentation* (volteos

horizontales, rotaciones, zoom y variaciones de contraste) con el fin de aumentar la variabilidad de los datos y mitigar el sobreajuste.

Arquitectura de la red

La red se estructuró como una secuencia de bloques convolucionales, cada uno compuesto por una capa Conv2D, una capa de normalización por lotes (*BatchNormalization*) y una capa de MaxPooling.

La elección de capas Conv2D responde a que las operaciones de convolución constituyen la herramienta fundamental para el procesamiento de imágenes. En lugar de analizar cada píxel de forma aislada, aplican filtros que recorren la imagen y aprenden a detectar patrones locales: en las capas iniciales, bordes y texturas simples; en las capas más profundas, estructuras complejas como masas o microcalcificaciones. Además, la convolución comparte parámetros —un mismo filtro se aplica a toda la imagen—, lo que reduce significativamente la cantidad de parámetros frente a una red densa y aporta invariancia a la traslación, propiedad relevante dado que una lesión puede localizarse en cualquier región de la mama.

La elección de capas MaxPooling responde a la necesidad de reducir progresivamente la dimensión espacial de los mapas de características (de 1024 hasta 16 píxeles). Esta operación disminuye el costo computacional y, al conservar el valor máximo de cada región, retiene la activación más significativa y otorga cierta tolerancia a pequeños desplazamientos. La red se completa con una capa de *Global Average Pooling*, capas densas con regularización por *dropout* y una neurona de salida con activación sigmoide que devuelve la probabilidad de malignidad.

Entrenamiento

El modelo se compiló con el optimizador Adam (tasa de aprendizaje 1×10^{-4}) y función de pérdida de entropía cruzada binaria. Se realizaron dos corridas de entrenamiento, de 20 y 40 épocas respectivamente, con el objetivo de analizar el efecto de la cantidad de épocas sobre el desempeño del modelo. El conjunto se dividió de forma estratificada en entrenamiento, validación y test.

Resultados obtenidos

Epocas	Accuracy	Val Acurracy	Loss	Val Loss	AUC	Tiempo
20	0.7496	0.7433	0.6525	0.6594	0.6346	1,16 h
40	0.7190	0.3937	0.6430	0.7700	0.6447	2,33 h

En la corrida de 20 épocas, el modelo alcanzó una accuracy de entrenamiento de 0,75 y de validación de 0,74, con un AUC en torno a 0,63, con un tiempo de entrenamiento de aproximadamente 1,16 horas. En la corrida de 40 épocas, la accuracy de entrenamiento se mantuvo en un valor similar (0,72), pero la accuracy de validación descendió a 0,39, con un incremento de la pérdida de validación a 0,77 y un tiempo de entrenamiento de 2,33 horas. El AUC final se ubicó alrededor de 0,64

Interpretación de resultados

El primer hallazgo relevante es que duplicar la cantidad de épocas no mejoró el desempeño del modelo y, en validación, lo deterioró.

En la corrida de 20 épocas (Figura 1), la accuracy y la pérdida de entrenamiento (curvas azules) evolucionan de forma suave y estable: la accuracy de train asciende progresivamente hasta ubicarse en torno a 0,70-0,75 y la pérdida desciende de manera sostenida hasta estabilizarse cerca de 0,65. Las curvas de validación (naranjas), en cambio, ya muestran oscilaciones notorias —con caídas puntuales de la accuracy por debajo de 0,30 y picos de pérdida cercanos a 0,85—, aunque mantienen una tendencia general acompasada a la del entrenamiento. El AUC crece de forma relativamente pareja desde 0,57 hasta aproximadamente 0,63, lo que indica que en esta etapa el modelo todavía está aprendiendo patrones útiles.

En la corrida de 40 épocas (Figura 2), el panorama se agrava de manera evidente. La accuracy y la pérdida de entrenamiento se mantienen estables, prácticamente planas alrededor de 0,70 y 0,65 respectivamente, señal de que el modelo ya no incorpora información nueva del conjunto de entrenamiento. Sin embargo, las curvas de validación se vuelven mucho más erráticas que en la corrida anterior, con oscilaciones violentas de la accuracy entre 0,15 y 0,90 y picos de pérdida que se disparan por encima del valor de entrenamiento. El AUC, por su parte, asciende levemente hasta estancarse en torno a 0,64, prácticamente sin diferencia respecto del valor alcanzado en la mitad de las épocas.

El contraste entre ambas figuras es ilustrativo: el hecho de que la pérdida de validación se incremente y se vuelva inestable mientras la de entrenamiento permanece baja y estable constituye la firma característica del sobreajuste. El modelo continúa ajustándose a los datos de entrenamiento pero pierde capacidad de generalización sobre datos nuevos, comportamiento que se intensifica al extender el entrenamiento de 20 a 40 épocas. Se concluye que un mayor número de épocas no implica necesariamente un mejor modelo; superado cierto punto, solo se incrementa el tiempo de cómputo y el riesgo de memorización, sin ganancia alguna en la capacidad discriminativa real.

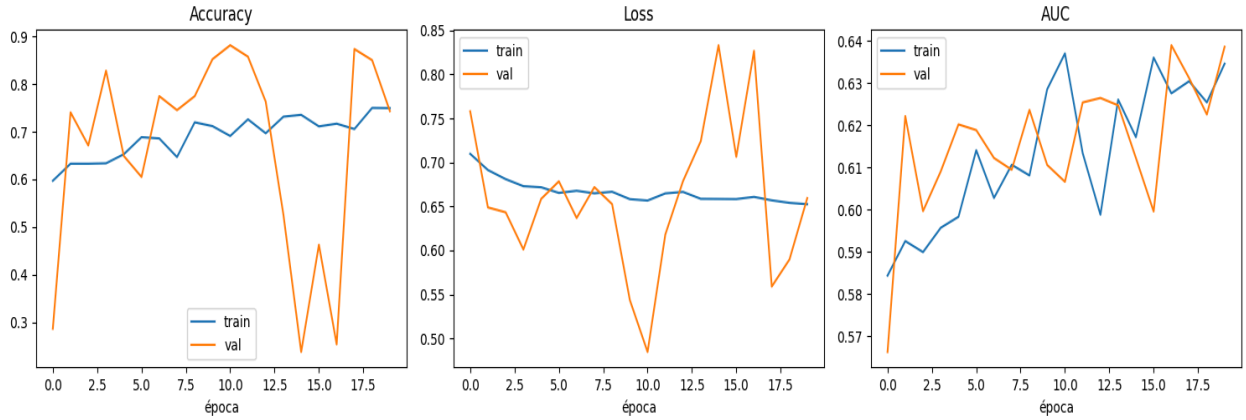


Figura 1: función de accuracy, loss y AUC con 20 épocas de entrenamiento.

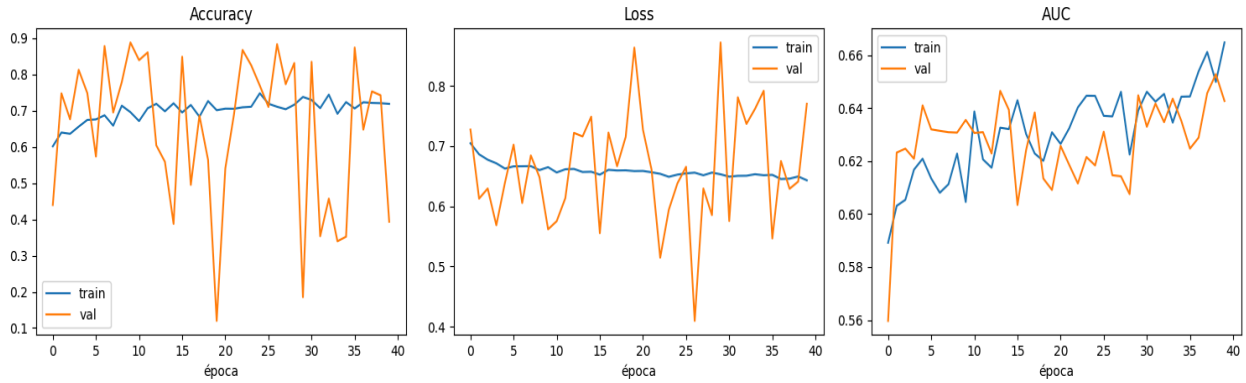


Figura 2: función de accuracy, loss y AUC con 40 épocas de entrenamiento.

El AUC, métrica independiente del umbral de decisión y por ello la más representativa del rendimiento global, se mantuvo en valores cercanos entre 0.63 y 0.66 en ambas corridas. A modo de contexto, un AUC de 0,5 equivale a una decisión aleatoria, mientras que los sistemas de nivel clínico como el de Google Health superan el 0,96. El valor obtenido se sitúa claramente por encima del azar —lo que confirma que la red aprendió patrones reales— pero muy por debajo de un umbral utilizable en la práctica clínica.

La curva ROC representa el equilibrio entre la sensibilidad y la tasa de falsos positivos a lo largo de todos los umbrales de decisión posibles. En ambas corridas (Figuras 3 y 4) la curva se ubica por encima de la diagonal de clasificación aleatoria, lo que confirma que la red posee capacidad discriminativa real, pero se mantiene próxima a ella, con un AUC cercano a 0,64: un valor superior al azar aunque alejado de la región superior izquierda del gráfico, donde se ubicarían los clasificadores de alto rendimiento. La escasa diferencia de AUC entre las corridas de 20 y 40 épocas evidencia que extender el entrenamiento no aportó una mejora real en la capacidad de distinguir casos malignos de benignos.

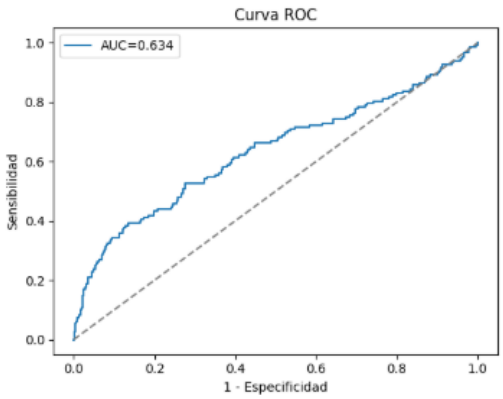


Figura 3: Curva ROC para 20 epocas

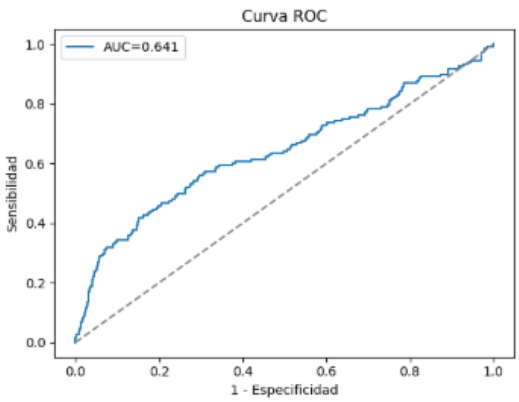


Figura 4: Curva ROC para 40 épocas

Entre las mejoras que habrían incrementado el desempeño se destacan, en orden de impacto esperado: el uso de transfer learning sobre una red pre entrenada (ResNet, EfficientNet, DenseNet), que constituye la mejora de mayor potencial; un mayor número de casos malignos reales para equilibrar el conjunto; una resolución superior para preservar lesiones de pequeño tamaño como las microcalcificaciones; y la incorporación de *early stopping* para detener el entrenamiento de forma automática ante el deterioro de la validación, evitando el sobreajuste observado en la corrida de 40 épocas.

En el siguiente link se podrá acceder a la implementación de la red neuronal convolucional de Google Colab y a las predicciones para las distintas épocas:
Implementación + predicciones

Reflexión crítica sobre la implementación de la IA en el sistema de salud

Aspectos éticos

Uno de los debates más relevantes es el de la responsabilidad sobre las decisiones médicas. La evidencia disponible demuestra que los sistemas de IA pueden superar la sensibilidad del lector humano individual y detectar una proporción significativa de cánceres que de otro modo se diagnosticarían tardíamente. Sin embargo, esta mejora técnica no resuelve la pregunta sobre quién responde cuando el sistema falla: si la IA omite un cáncer o genera un falso positivo que conduce a procedimientos invasivos innecesarios, la cadena de responsabilidad entre el médico, el hospital y el desarrollador del algoritmo permanece sin una respuesta jurídica clara.

Un segundo eje de debate es la equidad algorítmica. Los análisis realizados no evidenciaron sesgos significativos en el rendimiento del algoritmo entre los distintos grupos demográficos dentro de los umbrales operativos evaluados, pero ciertos subgrupos tienden a ser sobre-alertados cuando el modelo opera en rangos de mayor sensibilidad. Esto confirma que la equidad no puede darse por garantizada en el momento de la aprobación, sino que requiere vigilancia continua una vez el sistema está en funcionamiento.

A esto se suma el problema de la explicabilidad. Muchos modelos de aprendizaje profundo operan como una "caja negra" y no pueden justificar de forma inteligible por qué señalan una mamografía como sospechosa. En medicina, donde las decisiones deben poder ser explicadas a pacientes y revisadas por profesionales, esta falta de transparencia puede erosionar la confianza clínica y dificultar la aceptación institucional.

Finalmente, existe el riesgo del automation bias: a medida que la IA demuestra niveles crecientes de precisión, los radiólogos podrían reducir gradualmente su pensamiento crítico y aceptar las recomendaciones del sistema sin cuestionarlas. El modelo colaborativo, en el que la IA actúa como lector de apoyo y no como reemplazo del especialista, busca precisamente preservar la capacidad de juicio profesional, aunque cómo la experiencia acumulada con estos sistemas afecta la toma de decisiones a largo plazo es una pregunta que la evidencia actual aún no puede responder.

Aspectos regulatorios

El desafío regulatorio más relevante es el distribution shift o cambio en la distribución de los datos. Cuando los sistemas de IA se despliegan en entornos reales, los datos con los que operan difieren inevitablemente de aquellos con los que fueron calibrados, ya sea por cambios en la población, en los protocolos clínicos o en los equipos de imagen. Las consecuencias son concretas: se ha documentado que la tasa de derivaciones puede elevarse por encima de lo esperado pocas semanas después del inicio del despliegue, obligando a recalibrar los umbrales de decisión. Esto ilustra por qué aprobar un algoritmo como si fuera un dispositivo estático no es suficiente: a diferencia de un medicamento, una IA puede ver comprometido su rendimiento cuando cambia el contexto en el que opera.

La variabilidad de rendimiento según el tipo de equipo de mamografía es otro punto crítico. Incluso dentro de una misma marca, los modelos más modernos pueden producir patrones de imagen suficientemente distintos como para alterar significativamente el comportamiento del algoritmo. Esto evidencia la necesidad de validaciones multi-céntricas y multi-plataforma, y de no asumir que una aprobación obtenida en un contexto tecnológico sea transferible a otros.

Finalmente, el entrenamiento y la mejora continua de estos sistemas requieren grandes volúmenes de imágenes médicas, lo que obliga a garantizar el cumplimiento de normativas de privacidad, anonimización y consentimiento informado, especialmente cuando los datos circulan entre hospitales, empresas tecnológicas y organismos de investigación.

En conjunto, estos resultados respaldan un modelo regulatorio basado en la supervisión continua de los sistemas de IA. En lugar de limitar la evaluación al momento de su aprobación, se propone realizar controles periódicos que permitan verificar su desempeño y corregir posibles desviaciones, garantizando así su seguridad, eficacia y equidad durante toda su utilización clínica.

Aspectos de adopción en el sistema de salud

Uno de los hallazgos más atractivos para la adopción institucional es la reducción de la carga de trabajo radiológico. Distintos estudios han documentado reducciones de entre un 32% y un 44% en el tiempo de lectura cuando la IA reemplaza al segundo lector humano, manteniendo o mejorando la capacidad de detección. Esto resulta especialmente relevante en sistemas de salud que enfrentan escasez de especialistas y una demanda creciente de estudios diagnósticos.

Sin embargo, la investigación ha identificado barreras organizacionales concretas: muchos centros de tamizaje siguen operando con flujos de trabajo en papel, y los sistemas informáticos institucionales frecuentemente carecen de funcionalidad para registrar automáticamente los resultados del algoritmo. El principal obstáculo a la adopción ya no es tecnológico, sino operacional y normativo.

La aceptación profesional es otro factor determinante. La evidencia disponible apunta con consistencia a un modelo colaborativo en el que la IA actúa como segundo lector o sistema de triaje, preservando el rol del radiólogo para tareas de mayor complejidad clínica. Los ensayos más robustos hasta la fecha han adoptado este diseño y obtenido resultados favorables, lo que ofrece una base empírica sólida para presentar la IA como aliada y no como amenaza.

Por último, la adopción requiere construir confianza pública. La evidencia sobre detección más temprana de tumores invasivos y reducción de cánceres diagnosticados tardíamente son datos que pueden contribuir a ello, siempre que se comuniquen de manera transparente. Sin una adecuada aceptación por parte de la sociedad y del personal sanitario, incluso los sistemas con mejores resultados clínicos pueden encontrar resistencia para su implementación en programas nacionales de detección temprana del cáncer de mama.

Conclusión

La pregunta que orientó este trabajo no admite una respuesta binaria. La evidencia disponible no permite concluir que la IA sea confiable en términos absolutos, pero tampoco que no lo sea: permite algo más preciso y útil, que es establecer en qué condiciones puede serlo.

Los resultados analizados demuestran que los sistemas de IA actuales son capaces de detectar más cánceres reales que un lector humano individual, reducir los cánceres diagnosticados tardíamente y liberar una proporción significativa de la carga de trabajo radiológica, todo ello sin incrementar la tasa de falsas alarmas. Desde el punto de vista técnico, el rendimiento es sólido y, en ciertos indicadores clínicos, superior al estándar humano. En ese sentido, el nivel de confianza en estas herramientas como sistemas de apoyo diagnóstico está respaldado por evidencia robusta.

Sin embargo, esa confianza tiene condiciones. El rendimiento de un sistema de IA no es fijo, puede degradarse cuando cambia el equipo de imagen, la población atendida o los protocolos clínicos, y ese deterioro puede pasar desapercibido si no existe un mecanismo de monitoreo continuo. La aprobación puntual de un algoritmo no garantiza su seguridad en el tiempo. Confiar en la IA exige, por lo tanto, un marco de supervisión activa, no una validación inicial y un uso indefinido.

En cuanto a su integración en el flujo clínico, la evidencia es igualmente clara: los mejores resultados se obtienen cuando la IA actúa como complemento del radiólogo y no como un sistema completamente autónomo. La IA prioriza casos, señala zonas sospechosas y libera al radiólogo del volumen más rutinario; el radiólogo aporta el juicio clínico, el contexto de la paciente y la responsabilidad sobre la decisión final. Ninguno reemplaza al otro: cada uno compensa las limitaciones del otro. Los ensayos más rigurosos hasta la fecha adoptaron exactamente ese diseño y obtuvieron los mejores resultados.

La implementación propia desarrollada en este trabajo confirmó, desde otro ángulo, el mismo principio: construir un clasificador funcional es posible incluso con recursos limitados, pero la brecha entre un modelo académico y uno de uso clínico no es algorítmica sino de datos, validación y contexto. Esa brecha es la que los grandes estudios poblacionales están comenzando a cerrar, con resultados que justifican una confianza creciente, siempre que vaya acompañada de supervisión, transparencia y un rol humano que permanezca en el centro de la decisión médica.

Bibliografía

McKinney, S. M., Sieniek, M., Godbole, V., et al. (2020). International evaluation of an AI system for breast cancer screening. Nature, 577(7788), 89–94. doi: 10.1038/s41586-019-1799-6

Lång, K., Josefsson, V., Larsson, A-M., et al. (2023). Artificial intelligence-supported screen reading versus standard double reading in the Mammography Screening with Artificial Intelligence trial (MASAI): a clinical safety analysis. The Lancet Oncology, 24(8), 936–944. doi: 10.1016/S1470-2045(23)00298-X

Gommers, J., Hernström, V., Josefsson, V., et al. (2026). Interval cancer, sensitivity, and specificity comparing AI-supported mammography screening with standard double reading without AI in the MASAI study. The Lancet, 407(10527), 505–514. doi: 10.1016/S0140-6736(25)02464-X

Medscape. (2023). La IA mejora la detección del cáncer de mama en el cribado poblacional en Suecia. Recuperado de https://espanol.medscape.com/verarticulo/5911720?form=fpf

Univadis. (2023). Suecia evalúa el uso de la IA en su programa comunitario de detección del cáncer de mama. Recuperado de https://www.univadis.es/viewarticle/suecia-eval%C3%BA-el-uso-de-la-ia-en-su-programa-comunitario-2023a1000hr9

Kelly, C. J., Wilson, M., Warren, L. M., et al. (2026). Artificial intelligence for breast cancer screening in routine clinical practice: Early experience from a population-based screening program. Nature Cancer, 7(3). doi: 10.1038/s43018-026-01127-0

OpenAI. (2026). ChatGPT (GPT-5.5) [Modelo de lenguaje de gran escala]. https://chatgpt.com/

Anthropic. (2026). Claude [Modelo de lenguaje de gran escala]. https://claude.ai/